

RAPPORT DE PROJET

Pipeline Data Engineering sur Azure

Phase 0 — Documentation et Etude Prelable

1. Azure SQL Database

Definition

Azure SQL Database est un service de base de donnees relationnelle entierement gere (PaaS - Platform as a Service) propose par Microsoft Azure. Base sur le moteur SQL Server, il offre une haute disponibilite, des sauvegardes automatiques et une scalabilite elastique sans necessiter de gestion d'infrastructure.

Cas d'usage

- Stockage de donnees transactionnelles structurees
- Applications OLTP (Online Transaction Processing)
- Source de donnees pour pipelines ETL/ELT
- Reporting et analyses operationnelles

Avantages

- Haute disponibilite avec SLA a 99,99%
- Sauvegardes automatiques et restauration point-in-time
- Securite avantee : chiffrement, pare-feu, Azure Active Directory
- Scalabilite verticale et horizontale
- Compatibilite native avec l'ecosysteme Azure

Role dans le projet

Dans ce projet, Azure SQL Database constitue la source principale de donnees structurees. Elle heberge trois tables metier : Products (catalogue produits), Stores (magasins) et Transactions (ventes). Ces donnees sont ensuite extraites via Azure Data Factory vers la couche Bronze du Data Lake.

2. Azure Data Lake Storage Gen2 (ADLS Gen2)

Fonctionnement

Azure Data Lake Storage Gen2 est une solution de stockage massif d'objets optimisee pour l'analytique Big Data. Elle combine les capacites de stockage d'Azure Blob Storage avec un systeme de fichiers hierarchique (Hierarchical Namespace), permettant des operations performantes sur les dossiers et fichiers.

Hierarchie de stockage et notion de container

Un container est l' unite logique de premier niveau dans ADLS Gen2 (equivalent d'un bucket). Il peut contenir une arborescence de dossiers et de fichiers. Dans ce projet, un seul container principal est cree, dans lequel sont organises les dossiers bronze, silver et gold.

Architecture Medallion

- Bronze : Données brutes ingérées sans transformation. Fichiers Parquet copiés directement depuis les sources (SQL, API JSON).
- Silver : Données nettoyées, typées, dédoublées et enrichies. Jointures réalisées entre les entités. Stockage au format Delta Lake.
- Gold : Agrégats métier prêts pour la consommation analytique et la visualisation dans Power BI. Calculs de KPIs : chiffre d'affaires, quantité vendue, valeur moyenne transactionnelle.

3. Azure Data Factory (ADF)

Definition

Azure Data Factory est un service d'intégration de données cloud entièrement géré. Il permet d'orchestrer des workflows d'ingestion, de transformation et de chargement de données (ETL/ELT) entre différentes sources et destinations, de manière visuelle et sans code ou via des scripts.

Composants principaux

- Pipelines : Flux de travail contenant une séquence d'activités. Ils définissent l'ordre d'exécution et les dépendances entre les étapes.
- Linked Services (Services liés) : Définitions de connexions aux sources et destinations de données (Azure SQL, ADLS Gen2, APIs HTTP...). Ce sont les 'connecteurs' d'ADF.
- Datasets : Représentations des structures de données utilisées (tables SQL, fichiers Parquet, endpoints JSON...). Ils référencent un Linked Service.
- Copy Activity : Activité principale de déplacement de données d'une source vers une destination avec options de mapping et de format.

Cas d'usage ETL / ELT

ADF est utilisé ici en mode ELT : les données sont d'abord copiées brutes (Extract & Load) vers Bronze, puis transformées ensuite par Databricks (Transform). Cela permet de conserver les données originales et de retraiter si nécessaire.

4. Databricks Community Edition

Présentation

Databricks est une plateforme analytique unifiée basée sur Apache Spark. La Community Edition est la version gratuite permettant d'expérimenter avec des clusters Spark, des notebooks collaboratifs et le traitement de données à grande échelle.

Notebooks et traitement distribué

- Notebooks interactifs : environnement de développement Python/PySpark avec exécution cellule par cellule, visualisations intégrées et documentation Markdown.
- Clusters Spark : ensemble de machines virtuelles (driver + workers) permettant le traitement distribué. Dans Community Edition, un seul nœud est disponible.
- Spark DataFrames : API de haut niveau pour manipuler des données tabulaires de manière distribuée, similaire aux DataFrames Pandas mais scalable sur des volumes massifs.

Cas d'usage dans le projet

Databricks est utilise pour les phases Silver et Gold : chargement des fichiers Parquet depuis Bronze, nettoyage (cast de types, deduplication), jointures entre entites, creation d'indicateurs calcules (total_amount), agregations metier, et sauvegarde au format Delta Lake.

Phase 1 — Preparation des Sources

1.1 Creation de la base Azure SQL

Une base de donnees Azure SQL a ete creee avec les trois tables suivantes :

Table	Colonnes principales	Description
Products	product_id, name, category, price	Catalogue des produits vendus
Stores	store_id, name, city, region	Liste des magasins du reseau retail
Transactions	transaction_id, product_id, store_id, quantity, date	Historique des ventes avec CLE ETRANGERE vers Products et Stores

1.2 Source API JSON — Customers

Une quatrieme source de donnees a ete integree via une URL publique GitHub au format JSON, contenant les informations clients (customer_id, name, email, city, country). Cette source represente un cas realiste d'integration d'une API REST externe dans un pipeline cloud.

Les 4 sources finales sont : Products, Stores, Transactions (Azure SQL) et Customers (API JSON GitHub).

Phase 2 — Creation du Data Lake

2.1 Storage Account et Container

Un Storage Account Azure a ete cree avec l'activation du Hierarchical Namespace (HNS), condition necessaire pour beneficier des capacites ADLS Gen2 : gestion des permissions ACL niveau dossier, performances optimisees pour Spark.

Un container principal a ete cree, servant de racine pour l'ensemble du Data Lake du projet.

2.2 Architecture Medallion — Structure des dossiers

Couche	Sous-dossiers	Contenu
Bronze	transaction, product, store, customer	Donnees brutes au format Parquet, copiees directement depuis les sources sans transformation
Silver	(fusion en un seul fichier Delta)	Donnees nettoyees, jointes, avec indicateur total_amount. Format Delta Lake
Gold	sales_by_date, sales_by_product...	Agregats metier calcules, prêts pour Power BI. Format CSV + Delta

Phase 3 — Orchestration avec Azure Data Factory

3.1 Services lies configures

Trois Linked Services ont ete configures dans Azure Data Factory pour couvrir l'ensemble des sources et destinations du pipeline :



AzureDataLakeStorage1	Azure Data Lake Storage Gen2 — Connexion au container de stockage (destination des donnees ingrees et source pour Databricks)
AzureSqlDatabase1	Azure SQL Database — Connexion a la base de donnees source contenant Products, Stores et Transactions
HttpServer1	HTTP — Connexion a l'API JSON publique GitHub pour l'ingestion des donnees Customers

3.2 Pipeline d'ingestion — 4 Copy Activities

Un pipeline ADF (pipeline1) a ete cree avec 4 activites Copy Data executees en sequence, chacune transferant une source vers le dossier Bronze du Data Lake au format Parquet :



Activite	Source	Destination Bronze	Format
Copy transaction	Azure SQL — Transactions	bronze/transaction/	Parquet
Copy store	Azure SQL — Stores	bronze/store/	Parquet
Copy product	Azure SQL — Products	bronze/product/	Parquet
Copy customers	API JSON GitHub	bronze/customer/	Parquet

Le pipeline a ete execute avec succes : statut "Operation reussie" (ID d'execution : dabb1837-28ac-4ee1-b716-1e7495d5c5a2). Les 4 fichiers Parquet ont ete verifies dans les dossiers Bronze correspondants.

Phase 4 — Databricks : Configuration du Cluster

4.1 Creation du cluster et du notebook

Un cluster Spark a ete cree dans Databricks Community Edition avec la configuration minimale requise. Un notebook PySpark a ete cree pour piloter l'ensemble des transformations Silver et Gold.

4.2 Montage du Data Lake (Mount)

Le Data Lake ADLS Gen2 a ete monte dans Databricks via le point de montage /mnt/datalake. Cette operation permet d'accéder aux fichiers du container comme s'ils etaient dans un systeme de fichiers local, en utilisant les credentials Azure (Client ID, Client Secret, Tenant ID).

Commande de montage (PySpark) :

```
dbutils.fs.mount(source="abfss://container@account.dfs.core.windows.net/",
mount_point="/mnt/datalake", extra_configs=configs)
```

Phase 5 — Traitement Silver

5.1 Chargement des donnees Bronze

Les 4 DataFrames ont ete charges depuis les fichiers Parquet de la couche Bronze :

- `df_transactions = spark.read.parquet('/mnt/datalake/bronze/transaction/')`
- `df_products = spark.read.parquet('/mnt/datalake/bronze/product/')`
- `df_stores = spark.read.parquet('/mnt/datalake/bronze/store/')`
- `df_customers = spark.read.parquet('/mnt/datalake/bronze/customer/')`

5.2 Nettoyage des donnees

Les operations de nettoyage suivantes ont ete realisees sur chaque DataFrame :

- Cast des types : conversion des colonnes numeriques (quantity en IntegerType, price en DoubleType, date en DateType)
- Suppression des doublons : `df.dropDuplicates()` sur chaque source
- Verification qualite : controle des valeurs nulles sur les colonnes cles (`transaction_id`, `product_id`, `store_id`)
- Standardisation : nettoyage des espaces et majuscules sur les champs textuels (noms de produits, villes)

5.3 Jointures et indicateur calcule

Les jointures entre les entites ont ete realisees pour construire un DataFrame unique enrichi :

- `transactions JOIN products ON product_id` (pour recuperer name, category, price)
- `JOIN stores ON store_id` (pour recuperer store_name, city, region)
- `JOIN customers ON customer_id` (pour associer les informations client)

L'indicateur calcule `total_amount = quantity x price` a ete ajoute comme colonne derivee.

5.4 Sauvegarde Silver

Le DataFrame Silver final a ete sauvegarde au format Delta Lake sur ADLS Gen2 :

```
df_silver.write.format("delta").mode("overwrite").save("/mnt/datalake/silver/")
```

Phase 6 — Traitement Gold

6.1 Agregations metier

La couche Silver a ete lue et 4 agregations metier ont ete calculees pour produire des datasets analytiques :

Aggregat	Dimension	Calcul
Sales by Date	date	SUM(total_amount), COUNT(transaction_id) GROUP BY date
Sales by Product	product_name, category	SUM(total_amount), SUM(quantity) GROUP BY product
Sales by Category	category	SUM(total_amount), COUNT DISTINCT transactions
Average Transaction Value	global	AVG(total_amount) par periode et par magasin

6.2 Sauvegarde Gold

Les datasets Gold ont ete sauvegardes au format Delta Lake dans /mnt/datalake/gold/, puis exportes en CSV pour import dans Power BI Desktop.